

## MASTER THESIS ASSIGNMENT No. 1366

Student: **Lovro Kovačić (0036533938)**

Study: Computing

Profile: Computer Science

Mentor: prof. Igor Mekterović, PhD

Title: **Comparison of autoregressive and discrete diffusion language models in planning and reasoning oriented tasks**

### Description:

The development of Large Language Models (LLMs) has mostly been based on the autoregressive (AR) paradigm, which generates text sequentially in a left-to-right manner. Discrete diffusion models have recently emerged as an alternative approach, enabling bidirectional context integration and iterative denoising. The introduction of remasking sampling strategies allows controlled resampling of uncertain tokens. Unlike AR models, which may propagate early generation errors, remasking diffusion-based models allow for the correction of errors in later denoising steps. The objective of this master's thesis is to investigate and compare three architectural paradigms, autoregressive models, standard discrete diffusion models, and diffusion models employing a remasking sampling mechanism, in the context of planning and reasoning tasks. Compared models will be of similar parameter sizes. The research will include the preparation of appropriate planning and reasoning benchmarks, selection and configuration of the three models, implementation of the resampling strategy, and a comparative analysis based on determined evaluation criteria. Evaluation criteria will include the accuracy rate on selected planning benchmarks and a qualitative assessment of the strengths and limitations of each architectural paradigm. The assessment aims to provide recommendations regarding the applicability of remasking diffusion models in agent-oriented planning scenarios. The final documentation will include a detailed description of the implemented remasking sampling architecture, accompanied by relevant segments of source code and technical explanations. The submission will provide the source code, experimental notebooks, and supplementary documentation.

Submission date: 26 June 2026

## **DIPLOMSKI ZADATAK br. 1366**

Pristupnik: **Lovro Kovačić (0036533938)**

Studij: Računarstvo

Profil: Računarska znanost

Mentor: prof. dr. sc. Igor Mekterović

Zadatak: **Usporedba autoregresijskih i diskretnih difuzijskih jezičnih modela u zadacima usmjerenim na planiranje i zaključivanje**

### Opis zadatka:

Razvoj velikih jezičnih modela (LLM) uglavnom se temelji na autoregresijskoj (AR) paradigmi, koja generira tekst sekvencijalno, slijeva nadesno. Kao alternativa nedavno su se pojavili diskretni difuzijski modeli koji omogućuju dvosmjernu integraciju konteksta i iterativno uklanjanje šuma. Uvođenjem strategije maskiranog uzorkovanja omogućuje se kontrolirano ponovno uzorkovanje nesigurnih tokena. Za razliku od AR modela, koji mogu propagirati pogreške ranijeg koraka generiranja, difuzijski modeli temeljeni na ponovnom maskiranju dopuštaju ispravljanje pogrešaka u kasnijim koracima uklanjanja šuma. Cilj rada je istražiti i usporediti tri arhitektonske paradigme: autoregresijske modele, standardne diskretne difuzijske modele i difuzijske modele koji koriste mehanizam maskiranog uzorkovanja, u kontekstu zadataka planiranja i rasuđivanja. Uspoređeni modeli bit će sličnih veličina parametara. Istraživanje će uključiti pripremu odgovarajućih okolina i mjerila za testiranje, odabir i konfiguraciju triju modela, provedbu strategije ponovnog uzorkovanja i komparativnu analizu temeljenu na postavljenim kriterijima ocjenjivanja. Kriteriji ocjenjivanja uključivat će stopu točnosti odabranih mjerila i kvalitativnu procjenu prednosti i ograničenja svake arhitektonske paradigme. Procjena ima za cilj pružiti preporuke u vezi s primjenjivošću maskiranih modela difuzije u scenarijima planiranja orijentiranim na agente. Rad će uključivati detaljan opis implementirane arhitekture uzorkovanja maskiranja, popraćen relevantnim segmentima izvornog koda i tehničkim objašnjenjima, kao i izvorni kod, eksperimentalne bilježnice i ostalu dodatnu dokumentaciju.

Rok za predaju rada: 26. lipnja 2026.